

**IMPLEMENTASI DETEKSI *PROMPT INJECTION* PADA *CHATBOT*  
BERBASIS *RETRIEVAL-AUGMENTED GENERATION* (RAG)**

**PROPOSAL SKRIPSI**

**RONALDO DAMIANUS PARULIAN SILITONGA**

**211401057**



**PROGRAM STUDI S-1 ILMU KOMPUTER**

**FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI**

**UNIVERSITAS SUMATERA UTARA**

**MEDAN**

**2026**

## 1. Rencana Judul

Implementasi Deteksi Prompt Injection pada Chatbot Berbasis *Retrieval-Augmented Generation* (RAG)

## 2. Bidang Ilmu

Computer Security and Intelligent Systems

## 3. Latar Belakang

Perkembangan *Large Language Models* (LLMs) telah mendorong pemanfaatan chatbot pada berbagai bidang, termasuk layanan pelanggan. Dibandingkan sistem tanya jawab konvensional, chatbot berbasis LLM mampu memahami pertanyaan pengguna secara lebih fleksibel, menghasilkan jawaban yang lebih natural, dan menyesuaikan respons dengan konteks percakapan. Dalam layanan pelanggan, kemampuan ini menjadi penting karena sistem tidak hanya dituntut menjawab pertanyaan sederhana, tetapi juga harus mampu memberikan informasi yang cepat, konsisten, dan relevan terhadap kebutuhan pengguna. Namun, kualitas layanan seperti itu tidak cukup hanya bergantung pada kemampuan generatif model, karena jawaban yang dihasilkan juga harus faktual dan sesuai dengan aturan atau pengetahuan domain yang digunakan oleh organisasi.

Salah satu pendekatan yang banyak digunakan untuk meningkatkan kualitas jawaban chatbot adalah *Retrieval-Augmented Generation* (RAG). Secara umum, RAG bekerja dengan cara mengambil informasi yang relevan dari basis pengetahuan eksternal, kemudian menggunakan informasi tersebut sebagai konteks dalam proses generasi jawaban. Pendekatan ini penting karena model generatif murni masih memiliki beberapa kelemahan, seperti kecenderungan menghasilkan informasi yang tidak faktual, sulit diperbarui pengetahuannya, dan kurang memiliki keahlian khusus pada domain tertentu. Dengan memanfaatkan *knowledge base* eksternal, chatbot dapat memberikan jawaban yang lebih *grounded*, lebih mudah diperbarui, dan lebih sesuai untuk domain layanan pelanggan yang bergantung pada dokumen seperti kebijakan, workflow, dan panduan penyelesaian masalah.

Dalam konteks layanan pelanggan, penggunaan RAG sangat relevan karena proses customer support pada praktiknya merupakan bentuk *knowledge-based reasoning*. Sistem harus mampu menghubungkan pertanyaan pengguna dengan dokumen yang tepat, lalu menghasilkan jawaban yang sesuai dengan aturan layanan yang berlaku. Dengan demikian, chatbot layanan pelanggan berbasis RAG bukan sekadar chatbot percakapan biasa, melainkan sistem yang menggabungkan pemahaman bahasa, pencarian informasi, dan pemanfaatan *knowledge base* secara terstruktur. Hal ini membuat kualitas *retrieval* menjadi sangat penting, karena kesalahan dalam pengambilan konteks dapat langsung memengaruhi kualitas jawaban yang diberikan kepada pengguna.

Meskipun RAG memberikan keuntungan yang besar, integrasi antara LLM dan sumber pengetahuan eksternal juga membuka celah keamanan baru, terutama prompt injection. Serangan ini terjadi ketika input yang diproses model mengandung instruksi yang dirancang untuk mengubah perilaku sistem dari tujuan aslinya. Pada aplikasi berbasis *retrieval*, ancaman ini menjadi lebih serius karena instruksi berbahaya tidak hanya dapat datang langsung dari pengguna, tetapi juga dapat muncul dari konten eksternal atau dokumen yang diambil sistem saat proses inferensi. Dalam kondisi ini, batas antara data dan instruksi menjadi semakin kabur, sehingga sistem dapat memproses teks yang seharusnya hanya menjadi sumber informasi seolah-olah merupakan perintah yang harus diikuti.

Bahaya dari prompt injection pada chatbot berbasis RAG tidak hanya sebatas menghasilkan jawaban yang salah, tetapi juga dapat mengganggu integritas layanan secara lebih luas. Literatur menunjukkan bahwa *prompt injection* pada aplikasi LLM terintegrasi dapat menyebabkan kebocoran *prompt internal*, manipulasi konten, pengumpulan informasi sensitif, fraud, hingga gangguan pada ketersediaan layanan. Pada konteks chatbot layanan pelanggan, dampak yang paling relevan adalah ketika sistem memberikan jawaban yang menyimpang dari kebijakan layanan, membocorkan instruksi internal, mengikuti perintah yang tidak sesuai dengan tujuan chatbot, atau menghasilkan informasi yang menyesatkan pengguna. Jika kondisi ini terjadi, maka chatbot tidak lagi berfungsi sebagai sistem bantuan pelanggan yang andal, melainkan menjadi sumber risiko baru bagi organisasi maupun pengguna.

Sejumlah penelitian juga menunjukkan bahwa prompt injection pada aplikasi nyata bukanlah persoalan teoritis. Studi pada aplikasi LLM terintegrasi memperlihatkan bahwa serangan yang efektif tidak selalu berbentuk frasa eksplisit seperti “ignore previous instructions”, tetapi dapat disusun agar tampak wajar, menyesuaikan format aplikasi, dan selaras dengan konteks input yang biasa diterima sistem. Dengan kata lain, input yang terlihat normal di permukaan tetap dapat membawa instruksi manipulatif yang memengaruhi proses *retrieval* maupun *generation*. Bahkan pada beberapa studi kasus chatbot aman berbasis RAG, sistem tanpa lapisan pertahanan tambahan masih dapat mengalami *role switching*, *prompt leakage*, atau respons yang menyimpang sebelum guardrails diterapkan. Temuan ini menunjukkan bahwa deteksi prompt injection memang diperlukan sebagai komponen keamanan di level aplikasi, bukan hanya sebagai kekhawatiran hipotetis.

Selain berasal dari input yang diberikan secara langsung oleh pengguna, secara konseptual konten berbahaya juga dapat muncul dari sumber pihak ketiga atau dari data yang sebelumnya tampak aman tetapi telah berubah ketika masuk ke alur pemrosesan sistem. Namun, pada penelitian ini fokus utama tetap diletakkan pada deteksi input berbahaya di level aplikasi dan konten, yaitu pada teks yang akhirnya diproses oleh chatbot, bukan pada analisis rinci serangan jaringan atau protokol komunikasi. Penegasan ini penting agar ruang lingkup penelitian tetap jelas, yaitu mengamankan proses *input–retrieval–generation* pada chatbot layanan pelanggan berbasis RAG.

Sebagai respons terhadap ancaman tersebut, berbagai pendekatan deteksi prompt injection telah dikembangkan, mulai dari banned terms, semantic similarity berbasis embeddings, classifier berbasis BERT, hingga multi-layer defense yang memadukan pemeriksaan input, validasi output, dan pembaruan aturan secara adaptif. Literatur terbaru juga menekankan bahwa detector yang baik tidak cukup hanya memiliki akurasi tinggi, tetapi juga harus menjaga *false positive rate* tetap rendah agar pertanyaan normal tidak terlalu sering diblokir. Hal ini sangat penting dalam konteks layanan pelanggan, karena chatbot harus tetap responsif dan nyaman digunakan oleh pengguna biasa, sambil tetap mampu menahan input yang berpotensi membelokkan proses komputasi RAG.

Dalam konteks bahasa Indonesia, dibutuhkan pula pendekatan deteksi yang sesuai dengan karakteristik teks yang digunakan pengguna. Untuk itu, model bahasa

Indonesia seperti IndoBERT menjadi relevan karena telah terbukti kuat untuk berbagai tugas pemahaman bahasa dan klasifikasi teks berbahasa Indonesia. Pemanfaatan model seperti IndoBERT diharapkan dapat membantu sistem membedakan pertanyaan layanan pelanggan yang normal dari input yang bersifat manipulatif atau berbahaya dengan lebih tepat. Dengan demikian, penerapan deteksi prompt injection pada chatbot layanan pelanggan berbasis RAG tidak hanya penting dari sisi keamanan, tetapi juga perlu disesuaikan dengan konteks bahasa yang menjadi lingkungan penggunaan sistem.

Berdasarkan uraian tersebut, dapat dilihat bahwa chatbot layanan pelanggan berbasis RAG memang menawarkan potensi besar dalam meningkatkan kualitas layanan, tetapi pada saat yang sama juga menghadapi risiko nyata berupa prompt injection yang dapat menurunkan keandalan sistem. Oleh karena itu, penelitian ini mengangkat topik Implementasi Deteksi Prompt Injection pada Chatbot Layanan Pelanggan Berbasis RAG dengan tujuan membangun sistem yang tidak hanya informatif dan relevan terhadap knowledge base, tetapi juga lebih aman terhadap input berbahaya. Penelitian ini diharapkan dapat memberikan kontribusi pada pengembangan chatbot layanan pelanggan berbahasa Indonesia yang lebih andal, aman, dan sesuai untuk kebutuhan penggunaan nyata.

#### **4. Rumusan Masalah**

Permasalahan utama dalam penelitian ini terletak pada penggunaan chatbot layanan pelanggan berbasis *Retrieval-Augmented Generation* (RAG) yang di satu sisi mampu meningkatkan kualitas jawaban melalui pemanfaatan knowledge base, tetapi di sisi lain membuka celah keamanan baru berupa prompt injection. Pada kondisi ini, chatbot tidak hanya dituntut untuk memberikan respons yang relevan, faktual, dan sesuai dengan kebutuhan pengguna, tetapi juga harus mampu menjaga agar proses pengambilan informasi dan generasi jawaban tidak mudah dipengaruhi oleh input yang bersifat manipulatif atau berbahaya.

Selain itu, dalam konteks penggunaan bahasa Indonesia, dibutuhkan pendekatan deteksi yang tidak hanya memperhatikan pola serangan secara umum, tetapi juga mampu memahami karakteristik teks berbahasa Indonesia agar pembedaan antara pertanyaan normal dan input berbahaya dapat dilakukan dengan lebih tepat. Oleh karena itu, inti permasalahan penelitian ini terletak pada bagaimana membangun

chatbot layanan pelanggan berbasis RAG yang tetap informatif sekaligus aman, sehingga sistem dapat digunakan secara lebih andal dalam menghadapi risiko prompt injection tanpa mengganggu fungsi utamanya sebagai layanan tanya jawab.

## 5. Batasan Masalah

Untuk batasan masalah dalam penelitian ini ditetapkan sebagai berikut:

1. Penelitian difokuskan pada pengembangan chatbot layanan pelanggan berbasis teks, sehingga pengujian dibatasi pada input, output, dan sumber *retrieval* dalam bentuk teks, serta tidak mencakup skenario multimodal seperti gambar, suara, atau video.
2. Sistem chatbot dibangun menggunakan pendekatan *Retrieval-Augmented Generation* (RAG) dengan memanfaatkan knowledge base sebagai sumber utama dalam menghasilkan jawaban. Knowledge base dibatasi pada dokumen layanan pelanggan, seperti kebijakan layanan, alur layanan, dan panduan penyelesaian masalah.
3. Penelitian berfokus pada deteksi prompt injection pada level input dan konten teks yang diproses chatbot, termasuk kemungkinan instruksi berbahaya yang muncul melalui dokumen atau hasil *retrieval*, sehingga pembahasan diarahkan pada gangguan terhadap proses *retrieval* dan *generation*.
4. Pendekatan deteksi yang digunakan dibatasi pada kombinasi rule-based guardrails dan model klasifikasi berbasis IndoBERT dalam konteks bahasa Indonesia, tanpa melakukan perbandingan luas dengan banyak model atau metode deteksi lainnya.
5. Penelitian ini tidak membahas secara mendalam aspek keamanan pada level jaringan, protokol komunikasi, malware, atau serangan berbasis volume seperti DDoS, karena hal-hal tersebut berada di luar fokus utama penelitian dan hanya diposisikan sebagai konteks ancaman lanjutan.
6. Evaluasi penelitian dibatasi pada kemampuan sistem dalam menjawab pertanyaan layanan pelanggan serta membedakan input normal dan input yang terindikasi prompt injection pada tahap prototype dan pengujian akademik, sehingga belum mencakup deployment penuh pada lingkungan produksi nyata.

## 6. Tujuan Penelitian

Penelitian ini bertujuan untuk mengembangkan chatbot layanan pelanggan berbasis *Retrieval-Augmented Generation* (RAG) yang mampu memberikan jawaban secara relevan, faktual, dan sesuai dengan knowledge base yang digunakan, sekaligus dilengkapi dengan mekanisme deteksi prompt injection agar sistem tidak mudah dipengaruhi oleh input atau konten *retrieval* yang bersifat manipulatif. Selain membangun sistem chatbot yang berfungsi sebagai layanan tanya jawab, penelitian ini juga bertujuan menerapkan pendekatan rule-based guardrails dan model klasifikasi berbasis IndoBERT dalam konteks bahasa Indonesia, sehingga proses deteksi dapat dilakukan dengan lebih sesuai terhadap karakteristik teks yang digunakan pengguna.

Pada akhirnya, penelitian ini diarahkan untuk mengetahui sejauh mana penerapan deteksi prompt injection dapat meningkatkan keamanan chatbot layanan pelanggan berbasis RAG tanpa mengurangi fungsi utamanya sebagai sistem yang tetap responsif, informatif, dan layak digunakan pada tahap prototype akademik.

## 7. Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat secara akademik maupun praktis. Secara akademik, penelitian ini diharapkan dapat menambah kontribusi pada pengembangan kajian di bidang Natural Language Processing, khususnya pada penerapan *Retrieval-Augmented Generation* (RAG) dan deteksi prompt injection pada chatbot layanan pelanggan. Penelitian ini juga diharapkan dapat memperkaya referensi mengenai pengembangan sistem chatbot yang tidak hanya berfokus pada kualitas jawaban, tetapi juga pada aspek keamanan interaksi, terutama dalam konteks bahasa Indonesia dengan pemanfaatan model seperti IndoBERT.

Secara praktis, penelitian ini diharapkan dapat memberikan gambaran implementasi chatbot layanan pelanggan yang mampu memanfaatkan knowledge base secara lebih efektif sekaligus memiliki perlindungan terhadap input berbahaya yang dapat mengganggu proses *retrieval* dan *generation*. Hasil penelitian ini diharapkan dapat menjadi acuan awal bagi pengembangan sistem chatbot layanan pelanggan yang lebih aman, lebih andal, dan lebih sesuai untuk kebutuhan penggunaan nyata, serta

membuka peluang pengembangan teknologi chatbot berbahasa Indonesia yang tidak hanya informatif, tetapi juga lebih adaptif terhadap risiko keamanan pada level aplikasi.

## **8. Metodologi Penelitian**

### **8.1 Studi Pustaka**

Penelitian ini diawali dengan melakukan studi pustaka untuk memperoleh pemahaman yang mendalam mengenai teori, metode, dan teknologi yang menjadi dasar penelitian. Kajian pustaka difokuskan pada beberapa topik utama, yaitu chatbot layanan pelanggan, *Retrieval-Augmented Generation* (RAG), prompt injection, deteksi dan mitigasi prompt injection, serta model bahasa Indonesia seperti IndoBERT. Tahap ini dilakukan dengan menelaah jurnal, paper, dan sumber ilmiah lain yang relevan agar penelitian memiliki dasar teoritis yang kuat serta arah implementasi yang jelas.

Melalui studi pustaka, penelitian tidak hanya mengumpulkan teori, tetapi juga mengidentifikasi bentuk ancaman prompt injection yang relevan pada chatbot berbasis RAG, pendekatan deteksi yang realistis untuk diterapkan, serta posisi penelitian terhadap studi-studi terdahulu. Dengan demikian, tahap ini menjadi dasar dalam menentukan bentuk sistem, jenis data yang dibutuhkan, dan metode evaluasi yang akan digunakan.

### **8.2 Pengumpulan Data dan Penyusunan Dataset**

Tahap ini bertujuan untuk menyiapkan seluruh data yang dibutuhkan dalam penelitian, baik untuk pembangunan chatbot maupun untuk pengujian modul deteksi prompt injection. Data yang digunakan terdiri dari dua kelompok utama, yaitu data knowledge base dan data evaluasi. Data knowledge base berupa dokumen layanan pelanggan yang akan menjadi sumber jawaban chatbot, sedangkan data evaluasi berupa pertanyaan normal dan input yang mengandung prompt injection.

Pada tahap ini, proses yang dilakukan meliputi:

1. Pengumpulan dokumen knowledge base, Dokumen yang dikumpulkan berupa kebijakan layanan, alur layanan, syarat



layanan, pertanyaan umum, dan panduan penyelesaian masalah yang relevan dengan domain chatbot layanan pelanggan.

2. Pengumpulan data pertanyaan normal, Data ini berisi pertanyaan-pertanyaan yang wajar diajukan pengguna dalam konteks layanan pelanggan, seperti pertanyaan mengenai prosedur, persyaratan, jadwal, atau kendala layanan.
3. Penyusunan data prompt injection, Data serangan disusun berdasarkan pola-pola prompt injection dari literatur, seperti perintah untuk mengabaikan instruksi sebelumnya, upaya meminta system prompt, role switching, instruction override, dan bentuk manipulasi lain yang disesuaikan ke konteks bahasa Indonesia.
4. Penyusunan skenario indirect prompt injection berbasis teks, Selain input berbahaya langsung dari pengguna, penelitian ini juga menyiapkan konten teks berbahaya yang dapat disisipkan ke dokumen atau hasil retrieval, sehingga pengujian tetap dapat mencakup indirect prompt injection dalam ruang lingkup sistem berbasis teks.
5. Pembersihan dan pelabelan data, Data yang telah dikumpulkan kemudian dibersihkan, diseleksi, dan diberi label sesuai kategorinya, misalnya normal atau prompt injection.
6. Pembagian dataset, Dataset dibagi ke dalam data pelatihan, validasi, dan pengujian agar proses pembangunan dan evaluasi model dapat dilakukan secara lebih terukur.

Untuk knowledge base, dokumen yang telah dikumpulkan selanjutnya dipersiapkan melalui proses cleaning, chunking, dan embedding agar dapat digunakan dalam sistem RAG. Setiap potongan dokumen disimpan dalam media penyimpanan yang mendukung pencarian semantik, sehingga chatbot dapat mengambil konteks yang relevan ketika menerima pertanyaan dari pengguna.

### 8.3 Analisis dan Perancangan Sistem

Setelah data dan knowledge base siap, penelitian dilanjutkan dengan tahap analisis dan perancangan sistem. Pada tahap ini ditentukan komponen utama chatbot layanan pelanggan berbasis RAG beserta posisi modul deteksi prompt injection di dalam alur sistem. Sistem dirancang agar setiap input pengguna terlebih dahulu diperiksa oleh modul deteksi sebelum diteruskan ke proses retrieval dan generation.

Secara umum, alur sistem dirancang sebagai berikut:

1. Pengguna memasukkan pertanyaan ke chatbot
2. Input diperiksa oleh modul deteksi prompt injection
3. Jika input aman, sistem melakukan *retrieval* ke knowledge base
4. Hasil retrieval digunakan sebagai konteks untuk proses generation
5. Chatbot menghasilkan jawaban berdasarkan knowledge base
6. Jika input terindikasi berbahaya, sistem menolak atau menghentikan proses

Perancangan ini bertujuan agar chatbot tetap menjalankan fungsi utamanya sebagai layanan tanya jawab, tetapi juga memiliki lapisan keamanan yang mampu menahan input atau konten yang dapat mengganggu proses retrieval dan generation.

### 8.4 Perancangan Sistem

Tahap implementasi mencakup pembangunan chatbot layanan pelanggan berbasis RAG dan pembangunan modul deteksi prompt injection. Pada sisi chatbot, sistem diimplementasikan agar mampu menerima pertanyaan pengguna, melakukan retrieval terhadap knowledge base, dan menghasilkan jawaban yang tetap berlandaskan dokumen yang relevan. Pada sisi keamanan, modul deteksi dibangun menggunakan pendekatan gabungan antara rule-based guardrails dan model klasifikasi berbasis IndoBERT.

Secara lebih rinci, implementasi sistem dilakukan melalui langkah-langkah berikut:

1. Membangun knowledge base berbasis dokumen layanan pelanggan
2. Menghubungkan knowledge base dengan mekanisme retrieval
3. Membangun chatbot berbasis RAG untuk menghasilkan jawaban
4. Menyusun aturan rule-based guardrails untuk mendeteksi pola serangan eksplisit
5. Menyiapkan dan menerapkan model IndoBERT untuk klasifikasi input
6. Mengintegrasikan modul deteksi dengan pipeline chatbot
7. Menguji integrasi seluruh komponen sistem

Melalui tahap ini, diharapkan sistem yang dibangun dapat berfungsi sebagai chatbot layanan pelanggan yang tetap informatif dan memiliki perlindungan dasar terhadap prompt injection pada level aplikasi.

## 8.5 Pengujian dan Evaluasi

Setelah sistem selesai diimplementasikan, tahap berikutnya adalah pengujian dan evaluasi. Pengujian dilakukan untuk melihat dua aspek utama, yaitu kemampuan chatbot dalam menjawab pertanyaan normal layanan pelanggan dan kemampuan sistem dalam mendeteksi prompt injection.

Pengujian dilakukan melalui beberapa skenario, yaitu:

1. Pengujian chatbot tanpa mekanisme deteksi, bertujuan untuk melihat perilaku dasar sistem ketika menerima pertanyaan normal maupun input berbahaya.
2. Pengujian chatbot dengan rule-based guardrails, bertujuan untuk melihat kontribusi aturan sederhana dalam mendeteksi serangan yang eksplisit.
3. Pengujian chatbot dengan kombinasi rule-based guardrails dan IndoBERT, bertujuan untuk mengevaluasi efektivitas pendekatan hybrid dalam membedakan input normal dan prompt injection.

Evaluasi dilakukan menggunakan metrik:

- Accuracy
- Precision
- Recall
- F1-score

- Confusion Matrix

Selain itu, penelitian ini juga memperhatikan false positive rate, karena sistem deteksi yang baik tidak hanya harus mampu menangkap serangan, tetapi juga tidak terlalu sering salah menandai pertanyaan normal sebagai berbahaya. Dengan demikian, evaluasi diarahkan untuk melihat keseimbangan antara keamanan sistem dan kegunaan chatbot.

## **8.6 Analisis Hasil dan Dokumentasi**

Tahap terakhir adalah analisis hasil dan dokumentasi. Pada tahap ini, seluruh hasil pengujian dianalisis untuk melihat performa chatbot dan efektivitas deteksi prompt injection secara menyeluruh. Analisis dilakukan tidak hanya terhadap nilai metrik evaluasi, tetapi juga terhadap pola-pola hasil yang muncul, misalnya kondisi ketika sistem berhasil mendeteksi serangan, kondisi ketika pertanyaan normal masih salah ditandai, serta kondisi ketika kualitas jawaban chatbot tetap baik setelah mekanisme keamanan diterapkan.

Hasil analisis tersebut kemudian digunakan untuk menarik kesimpulan mengenai sejauh mana sistem yang dibangun mampu menjaga keseimbangan antara keamanan dan kegunaan. Seluruh tahapan penelitian, mulai dari studi pustaka, pengumpulan data, penyusunan dataset, perancangan, implementasi, pengujian, hingga analisis hasil, akan didokumentasikan secara sistematis ke dalam proposal dan laporan skripsi akhir agar dapat dipahami secara utuh dan dipertanggungjawabkan secara akademik.

## 9. Tinjauan Pustaka

Beberapa teori serta konsep yang dijadikan landasan dan acuan dalam penelitian ini dipaparkan sebagai berikut:

### 9.1 Chatbot Layanan Pelanggan

Chatbot merupakan sistem berbasis komputasi yang dirancang untuk berinteraksi dengan pengguna melalui bahasa alami. Dalam perkembangannya, chatbot tidak lagi hanya berfungsi sebagai sistem respons sederhana berbasis aturan, tetapi telah berkembang menjadi sistem yang memanfaatkan Large Language Models (LLMs) untuk memahami pertanyaan pengguna secara lebih fleksibel dan menghasilkan jawaban yang lebih natural. Dalam konteks layanan pelanggan, keberadaan chatbot menjadi penting karena sistem dituntut mampu memberikan bantuan secara cepat, konsisten, dan tersedia dalam skala besar tanpa selalu bergantung pada operator manusia. Dengan kemampuan tersebut, chatbot dapat dimanfaatkan untuk menjawab pertanyaan umum, memberikan panduan penggunaan layanan, menjelaskan prosedur, hingga membantu pengguna dalam menyelesaikan kendala tertentu.

Namun, kebutuhan layanan pelanggan pada praktiknya tidak hanya sebatas percakapan umum. Proses customer support umumnya bergantung pada kebijakan layanan, alur kerja, panduan penyelesaian masalah, dan data kontekstual yang harus dipahami sistem secara tepat. Penelitian pada domain customer support menunjukkan bahwa masalah ini dapat dipandang sebagai knowledge-based question answering problem, yaitu sistem harus mampu memetakan pertanyaan pengguna ke sumber pengetahuan yang relevan sebelum menghasilkan jawaban. Oleh karena itu, chatbot layanan pelanggan yang baik tidak cukup hanya mengandalkan kemampuan generatif model, tetapi juga perlu memiliki keterhubungan yang kuat dengan knowledge base yang sesuai dengan domain layanan. Dengan demikian, chatbot layanan pelanggan dalam penelitian ini diposisikan sebagai sistem tanya jawab berbasis pengetahuan, bukan sekadar chatbot percakapan umum.

## 9.2 Retrieval-Augmented Generation (RAG)

*Retrieval-Augmented Generation* (RAG) merupakan pendekatan yang menggabungkan kemampuan model bahasa generatif dengan mekanisme pencarian informasi dari sumber pengetahuan eksternal. Pada pendekatan ini, sistem tidak langsung menghasilkan jawaban hanya dari pengetahuan yang tersimpan di parameter model, tetapi terlebih dahulu melakukan retrieval terhadap dokumen atau potongan informasi yang relevan, kemudian menggunakan hasil retrieval tersebut sebagai konteks dalam proses generasi jawaban. Dengan kata lain, RAG memadukan parametric memory dari model generatif dan non-parametric memory dari knowledge base eksternal, sehingga sistem dapat memberikan jawaban yang lebih faktual, lebih relevan terhadap domain, dan lebih mudah diperbarui ketika pengetahuan pada knowledge base berubah.

Pendekatan RAG menjadi penting karena model generatif murni masih memiliki beberapa keterbatasan, seperti hallucination, kesulitan memperbarui pengetahuan, serta keterbatasan pada domain yang membutuhkan informasi spesifik. Literatur survey RAG menjelaskan bahwa sistem ini secara umum dibangun dari tiga komponen utama, yaitu retriever, generator, dan retrieval fusion. Retriever bertugas mencari dokumen yang paling relevan terhadap query pengguna, generator bertugas menghasilkan jawaban, sedangkan retrieval fusion menentukan bagaimana hasil retrieval digabungkan dengan input sebelum diproses lebih lanjut oleh model. Struktur ini menjadikan RAG sangat sesuai untuk aplikasi yang membutuhkan jawaban berbasis dokumen, termasuk chatbot layanan pelanggan yang bergantung pada kebijakan layanan, workflow, dan panduan penyelesaian masalah.

Secara umum, struktur dasar RAG dalam penelitian ini dapat dipahami melalui beberapa komponen berikut:

1. Query Pengguna

Merupakan pertanyaan atau permintaan yang diberikan oleh pengguna kepada chatbot.

2. Retriever

Komponen yang bertugas mencari dokumen atau potongan teks yang paling relevan dari knowledge base berdasarkan query pengguna.

3. Knowledge Base / Vector Database

Merupakan sumber pengetahuan yang berisi dokumen layanan pelanggan, seperti kebijakan layanan, alur layanan, dan panduan penyelesaian masalah, yang telah diproses agar dapat dicari secara semantik.

4. Retrieved Context

Merupakan hasil pencarian berupa dokumen atau potongan teks yang dianggap paling relevan terhadap query pengguna.


5. Generator / LLM

Komponen yang menggunakan query pengguna dan hasil retrieval sebagai konteks untuk membentuk jawaban akhir.

6. Final Response

Jawaban yang dihasilkan chatbot dan dikirimkan kembali kepada pengguna.

Berdasarkan komponen tersebut, alur kerja RAG secara umum dapat dijelaskan seperti Gambar 1 berikut:



**Gambar 1.** Arsitektur Dasar *Retrieval-Augmented Generation (RAG)*

1. Pengguna memasukkan pertanyaan ke dalam sistem.
2. Pertanyaan tersebut diproses oleh retriever untuk dicari kecocokannya dengan knowledge base.
3. Sistem mengambil beberapa dokumen atau potongan teks yang paling relevan.
4. Hasil *retrieval* digabungkan dengan query pengguna sebagai konteks tambahan.
5. Model generatif menghasilkan jawaban berdasarkan query dan konteks retrieval tersebut.
6. Jawaban akhir dikirimkan kembali kepada pengguna.

Pada implementasi sistem berbasis RAG, kualitas jawaban sangat dipengaruhi oleh kualitas knowledge base dan kualitas retrieval. Oleh karena itu, dokumen layanan pelanggan umumnya perlu melalui beberapa tahap persiapan sebelum digunakan oleh sistem. Tahap-tahap tersebut meliputi cleaning, chunking, embedding, dan penyimpanan ke dalam vector database. Cleaning dilakukan untuk merapikan isi dokumen, chunking dilakukan untuk memecah dokumen menjadi unit informasi yang lebih kecil, embedding dilakukan untuk mengubah teks menjadi representasi vektor, dan vector database digunakan untuk menyimpan representasi tersebut agar pencarian semantik dapat dilakukan dengan lebih efisien. Literature survey RAG menegaskan bahwa keputusan pada tahap chunking dan retrieval sangat memengaruhi kualitas konteks yang akhirnya dipakai oleh generator


Dalam konteks penelitian ini, RAG dipilih karena chatbot layanan pelanggan membutuhkan jawaban yang tetap terhubung dengan knowledge base organisasi. Tanpa retrieval, model generatif lebih berisiko menjawab secara umum atau bahkan menghasilkan informasi yang tidak sesuai dengan kebijakan layanan. Dengan adanya RAG, chatbot dapat diarahkan untuk menjawab berdasarkan dokumen yang telah disiapkan, sehingga jawaban menjadi lebih grounded dan lebih sesuai untuk kebutuhan layanan pelanggan. Dengan demikian, RAG bukan hanya metode tambahan, tetapi menjadi komponen inti dalam sistem yang diusulkan pada penelitian ini.



### 9.3 Knowledge Base dalam Layanan Pelanggan

Knowledge base dalam layanan pelanggan merupakan kumpulan pengetahuan yang digunakan organisasi untuk memberikan jawaban secara konsisten kepada pengguna. Isi knowledge base biasanya tidak hanya berupa daftar pertanyaan umum, tetapi juga mencakup kebijakan layanan, prosedur, syarat, workflow penanganan masalah, dan panduan penyelesaian kendala. Pada praktiknya, dokumen-dokumen ini sering ditulis untuk dibaca manusia, sehingga tidak selalu langsung sesuai untuk diproses oleh model bahasa. Oleh karena itu, struktur dan representasi knowledge base menjadi komponen yang sangat penting dalam pengembangan chatbot layanan pelanggan.

Dalam sistem berbasis RAG, knowledge base biasanya dipersiapkan melalui proses cleaning, chunking, dan embedding agar dokumen dapat diproses dan dicari kembali secara lebih efektif seperti yang terlihat pada Gambar 2 di bawah ini.




**Gambar 2.** Transformasi Dokumen Layanan menjadi Knowledge Base RAG

Proses ini penting karena kualitas retrieval sangat dipengaruhi oleh bagaimana dokumen dipotong, disusun, dan direpresentasikan. Jika knowledge base terlalu panjang, ambigu, atau tidak terorganisasi dengan baik, maka sistem retrieval akan lebih mudah mengambil konteks yang tidak relevan. Oleh sebab itu, pada penelitian ini knowledge base tidak diposisikan hanya sebagai tempat penyimpanan informasi, tetapi sebagai komponen aktif yang menentukan kualitas jawaban chatbot.

## 9.4 Prompt Injection pada Sistem Berbasis RAG

Prompt injection merupakan salah satu ancaman utama pada aplikasi yang terintegrasi dengan Large Language Models (LLMs). Secara umum, prompt injection terjadi ketika input yang diproses model mengandung instruksi yang dirancang untuk mengubah perilaku sistem, sehingga model tidak lagi bekerja sesuai tujuan aslinya. Ancaman ini muncul karena model bahasa memproses teks secara fleksibel, sehingga batas antara teks yang seharusnya dianggap sebagai data dan teks yang seharusnya dianggap sebagai instruksi tidak selalu tegas. Akibatnya, penyerang dapat menyisipkan perintah tertentu agar model mengabaikan aturan sistem, membocorkan informasi, atau menghasilkan jawaban yang menyimpang.

Dalam literatur, prompt injection dibedakan menjadi direct prompt injection dan indirect prompt injection. Direct prompt injection terjadi ketika instruksi berbahaya dimasukkan langsung oleh pengguna ke dalam sistem. Sebaliknya, indirect prompt injection terjadi ketika instruksi berbahaya tersembunyi di dalam sumber data eksternal atau dokumen yang diambil sistem pada saat inferensi seperti yang terlihat pada Gambar 3 di bawah ini.



**Gambar 3.** Prompt Injection pada Sistem Berbasis RAG

Pada sistem berbasis RAG, prompt injection dapat memengaruhi dua proses utama, yaitu retrieval dan generation. Jika sistem mengambil dokumen yang telah dimodifikasi atau mengandung instruksi manipulatif, maka konteks yang digunakan model untuk menghasilkan jawaban menjadi tidak lagi aman. Dalam kondisi ini, komputasi RAG dapat terganggu karena model memproses teks retrieval bukan hanya sebagai sumber informasi, tetapi juga sebagai instruksi yang harus diikuti. Hal ini menyebabkan jawaban yang dihasilkan dapat menyimpang dari fungsi asli chatbot layanan pelanggan.

Berbagai literatur menunjukkan bahwa dampak prompt injection pada aplikasi LLM terintegrasi dapat berupa prompt leakage, manipulasi konten, information gathering, fraud, hingga gangguan terhadap ketersediaan layanan. Dalam konteks chatbot layanan pelanggan berbasis RAG, dampak yang paling relevan adalah ketika sistem memberikan jawaban yang tidak sesuai dengan kebijakan layanan, membocorkan instruksi internal, mengikuti perintah yang tidak seharusnya, atau menghasilkan respons yang menyesatkan pengguna. Oleh karena itu, prompt injection pada penelitian ini dipahami sebagai ancaman terhadap integritas jawaban dan keandalan sistem layanan pelanggan, sehingga keberadaannya perlu diantisipasi melalui mekanisme deteksi yang sesuai.

## **9.5 Deteksi dan Mitigasi Prompt Injection**

Deteksi prompt injection bertujuan untuk mengenali input atau konten yang berpotensi membelokkan perilaku model sebelum sistem menghasilkan jawaban. Salah satu pendekatan yang banyak digunakan adalah rule-based guardrails, yaitu aturan atau pola tertentu yang dirancang untuk menangkap serangan yang eksplisit, seperti upaya meminta system prompt, mengubah peran chatbot, atau menyuruh model mengabaikan instruksi sebelumnya. Pendekatan ini memiliki keunggulan dari sisi kesederhanaan dan kecepatan, sehingga sesuai digunakan sebagai lapisan awal pertahanan. Namun, kelemahan utamanya adalah serangan dapat diparafrasekan atau disamarkan sehingga tidak selalu dapat dideteksi hanya dengan aturan tetap.

Untuk mengatasi keterbatasan tersebut, beberapa penelitian menambahkan lapisan klasifikasi berbasis model bahasa, seperti BERT.

Pendekatan ini memungkinkan sistem mengenali prompt injection berdasarkan pola semantik dan konteks, bukan hanya berdasarkan keberadaan frasa tertentu. Dalam penelitian ini, model yang relevan digunakan adalah IndoBERT, karena sistem difokuskan pada konteks bahasa Indonesia. Dengan menggunakan IndoBERT, sistem diharapkan dapat lebih baik dalam membedakan pertanyaan layanan pelanggan yang normal dari input yang secara bentuk tampak wajar, tetapi sebenarnya memuat instruksi manipulatif. Dengan demikian, kombinasi rule-based guardrails dan IndoBERT menjadi pendekatan yang lebih kuat dibanding jika sistem hanya mengandalkan satu mekanisme deteksi saja. Lengkapnya, lapisan lapisan tersebut dideskripsikan pada Tabel 1 di bawah ini.

**Tabel 1.** Lapisan Deteksi Prompt Injection

| Lapisan               | Fungsi                                          |
|-----------------------|-------------------------------------------------|
| Rule-Based Guardrails | Menangkap pola serangan yang eksplisit          |
| IndoBERT Classifier   | Mengidentifikasi pola semantik yang lebih halus |
| Decision Layer        | Menentukan status aman atau berbahaya           |
| Output/Tindakan       | Menentukan ke RAG atau menolak input            |


Selain deteksi di sisi input, beberapa penelitian juga membahas mitigasi tambahan, seperti output validation dan feedback loop. Output validation digunakan untuk memeriksa apakah jawaban yang dihasilkan masih relevan, aman, dan tidak mengandung kebocoran informasi tertentu, sedangkan feedback loop digunakan untuk memperbarui aturan atau sistem deteksi berdasarkan pola serangan yang telah ditemukan. Meskipun penelitian ini tidak berfokus pada pengembangan seluruh lapisan mitigasi tersebut secara penuh, gagasan ini tetap penting sebagai landasan bahwa prompt injection akan lebih efektif ditangani jika sistem memiliki lebih dari satu lapisan perlindungan. Dalam proposal ini, fokus utama tetap diarahkan pada deteksi berbasis rule-based guardrails dan IndoBERT.

Salah satu hal penting dalam deteksi prompt injection adalah bahwa performa sistem tidak cukup dinilai hanya dari akurasi umum. Literatur terbaru menekankan pentingnya menjaga *false positive rate* tetap rendah, karena dalam penggunaan nyata sebagian besar input merupakan pertanyaan normal. Jika detector terlalu sensitif, maka sistem akan terlalu sering salah menolak pertanyaan biasa dan justru mengganggu fungsi layanan pelanggan. Oleh karena itu, deteksi prompt injection harus dipahami tidak hanya sebagai upaya menangkap serangan, tetapi juga sebagai upaya menjaga keseimbangan antara keamanan sistem dan kegunaan chatbot. Prinsip tersebut menjadi dasar penting dalam merancang dan mengevaluasi modul deteksi pada penelitian ini.

## 9.6 IndoBERT dan NLP Bahasa Indonesia

Dalam konteks penelitian ini, penggunaan model bahasa Indonesia menjadi penting karena chatbot dan modul deteksi dirancang untuk memproses teks berbahasa Indonesia. Salah satu sumber daya utama yang mendukung hal tersebut adalah IndoNLU, yaitu benchmark dan kumpulan sumber daya untuk evaluasi Natural Language Understanding bahasa Indonesia. Bersamaan dengan benchmark tersebut, dikembangkan pula model bahasa pra-latih seperti IndoBERT dan IndoBERT-lite, yang dirancang khusus untuk berbagai tugas bahasa Indonesia. Penelitian tersebut menunjukkan bahwa model monolingual Indonesia memiliki performa yang kuat, terutama pada tugas klasifikasi teks, dan pada banyak kasus mampu bersaing dengan model multilingual yang lebih umum.

IndoBERT ditempatkan sebagai komponen utama pada modul deteksi untuk memproses input teks berbahasa Indonesia. Untuk alurnya, teks masukan terlebih dahulu melalui tahap tokenisasi, kemudian diproses oleh model IndoBERT untuk dilakukan klasifikasi, sehingga sistem dapat membedakan apakah input termasuk kategori normal atau terindikasi sebagai prompt injection seperti yang terlihat pada Gambar 4 di bawah ini.



**Gambar 4.** Posisi IndoBERT dalam Modul Deteksi

Penggunaan IndoBERT pada penelitian ini pun menjadi relevan karena modul deteksi prompt injection pada dasarnya merupakan bentuk klasifikasi teks, yaitu membedakan apakah suatu input termasuk kategori normal atau berbahaya. Dibandingkan model yang dilatih untuk banyak bahasa sekaligus, model monolingual seperti IndoBERT memiliki keunggulan dalam menangkap karakteristik kosakata, struktur kalimat, dan nuansa bahasa Indonesia dengan lebih baik. Oleh karena itu, pemanfaatan IndoBERT dalam penelitian ini memiliki dasar teoritis yang kuat dan sesuai dengan kebutuhan sistem, terutama karena pengujian difokuskan pada pertanyaan layanan pelanggan dan kemungkinan prompt injection dalam bahasa Indonesia.

## 10. Penelitian Relevan

Beberapa penelitian terdahulu yang relevan digunakan dalam penelitian ini untuk menunjukkan landasan, keterkaitan, dan perbedaan penelitian yang akan dilakukan adalah sebagai berikut:

1. Su et al. (2025) melalui penelitian *LLM-Friendly Knowledge Representation for Customer Support* menunjukkan bahwa domain layanan pelanggan merupakan bentuk knowledge-based reasoning problem yang bergantung pada kebijakan,

workflow, troubleshooting, dan data kontekstual. Penelitian ini relevan karena memperkuat alasan pemilihan objek penelitian berupa chatbot layanan pelanggan berbasis knowledge base. Perbedaannya, penelitian Su et al. berfokus pada representasi pengetahuan dan fine-tuning untuk customer support, sedangkan penelitian ini menambahkan aspek keamanan prompt injection pada sistem berbasis RAG.

2. Abdelnabi et al. (2023) dalam penelitian *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* membahas ancaman indirect prompt injection pada aplikasi LLM terintegrasi. Penelitian ini menunjukkan bahwa instruksi berbahaya dapat masuk melalui konten eksternal atau hasil retrieval, bukan hanya dari input langsung pengguna. Penelitian ini sangat relevan karena menjadi dasar bahwa chatbot berbasis RAG memang rentan terhadap prompt injection, khususnya yang berasal dari sumber retrieval.
3. Liu et al. (2023) pada penelitian *Prompt Injection Attack against LLM-Integrated Applications* menunjukkan bahwa prompt injection pada aplikasi nyata dapat dilakukan secara sistematis dengan menyesuaikan konteks aplikasi. Penelitian ini relevan karena memperkuat bahwa prompt injection merupakan ancaman yang nyata dan tidak selalu hadir dalam bentuk eksplisit. Hasil penelitian ini juga menjadi dasar bahwa sistem deteksi tidak cukup hanya mengandalkan aturan sederhana, karena input berbahaya dapat disusun agar terlihat wajar.
4. Lan et al. (2025) melalui penelitian *Prompt Injection Detection in LLM Integrated Applications* membahas sistem deteksi prompt injection yang menggabungkan banned terms, vector embeddings, dan BERT. Penelitian ini relevan karena pendekatan deteksinya sangat dekat dengan penelitian yang diusulkan, khususnya pada penggunaan kombinasi rule-based dan classifier. Perbedaannya, penelitian Lan et al. bersifat umum pada aplikasi LLM, sedangkan penelitian ini menerapkannya pada chatbot layanan pelanggan berbasis RAG dalam konteks bahasa Indonesia.
5. Jacob et al. (2025) dalam penelitian *PromptShield: Deployable Detection for Prompt Injection Attacks* menekankan pentingnya detector prompt injection yang memiliki *false positive rate* rendah agar tetap layak diterapkan pada penggunaan nyata. Penelitian ini relevan karena memberikan dasar bahwa

evaluasi deteksi tidak cukup hanya dilihat dari akurasi umum, tetapi juga harus mempertimbangkan seberapa sering sistem salah menandai input normal sebagai serangan. Hal ini penting bagi chatbot layanan pelanggan yang harus tetap nyaman digunakan oleh pengguna normal.

6. Shih dan Kang (2025) melalui penelitian *Design and Implementation of a Secure RAG-Enhanced AI Chatbot for Smart Tourism Customer Service: Defending Against Prompt Injection Attacks* membahas chatbot berbasis RAG yang dilengkapi dengan guardrails untuk menghadapi prompt injection. Penelitian ini relevan karena menunjukkan contoh sistem chatbot layanan pelanggan berbasis RAG yang juga mempertimbangkan keamanan. Perbedaannya, penelitian tersebut berfokus pada domain smart tourism, sedangkan penelitian ini berfokus pada chatbot layanan pelanggan dengan pendekatan deteksi berbasis rule-based guardrails dan IndoBERT dalam bahasa Indonesia. Pendekatan deteksi berbasis rule-based guardrails dan IndoBERT dalam bahasa Indonesia.

## 11. Arsitektur Sistem


Arsitektur sistem pada penelitian ini dirancang untuk membangun chatbot layanan pelanggan berbasis *Retrieval-Augmented Generation* (RAG) yang dilengkapi dengan mekanisme deteksi prompt injection. Secara umum, sistem ini menggabungkan dua fungsi utama, yaitu fungsi layanan tanya jawab berbasis knowledge base dan fungsi perlindungan terhadap input atau konten retrieval yang berpotensi mengganggu proses pemrosesan. Pendekatan ini dipilih karena chatbot layanan pelanggan tidak hanya harus mampu memberikan jawaban yang relevan berdasarkan dokumen layanan, tetapi juga perlu menjaga agar proses retrieval dan generation tetap berjalan sesuai tujuan sistem.

Alur kerja sistem dimulai ketika pengguna memasukkan pertanyaan melalui chatbot. Input tersebut terlebih dahulu diperiksa oleh modul deteksi prompt injection yang terdiri dari rule-based guardrails dan IndoBERT classifier. Jika input dinyatakan aman, sistem akan meneruskan pertanyaan ke modul retriever untuk mencari dokumen atau potongan teks yang paling relevan dari knowledge base. Hasil retrieval tersebut kemudian digunakan sebagai konteks oleh generator/LLM untuk menghasilkan



jawaban akhir. Sebaliknya, jika input terindikasi berbahaya, sistem akan menolak atau menghentikan proses sebelum masuk ke tahap retrieval dan generation.

Knowledge base dalam sistem ini berisi dokumen layanan pelanggan seperti kebijakan layanan, alur layanan, dan panduan penyelesaian masalah. Agar dapat digunakan oleh sistem RAG, dokumen tersebut terlebih dahulu diproses melalui tahapan cleaning, chunking, dan embedding, lalu disimpan dalam media penyimpanan yang mendukung pencarian semantik. Dengan struktur ini, chatbot diharapkan mampu memberikan jawaban yang lebih grounded pada knowledge base, sementara modul deteksi membantu mencegah input atau konten retrieval berbahaya memengaruhi jawaban system, seperti yang terlihat pada Gambar 5 di bawah ini.



**Gambar 5.** Arsitektur Sistem yang Diusulkan

Secara keseluruhan, arsitektur yang diusulkan dapat dipahami sebagai chatbot layanan pelanggan berbasis RAG yang aman, yaitu sistem yang memadukan knowledge base, retrieval, generation, serta modul deteksi prompt injection dalam satu alur kerja. Dengan rancangan ini, penelitian diarahkan untuk menghasilkan prototype chatbot yang tidak hanya informatif dan relevan, tetapi juga memiliki perlindungan awal terhadap ancaman prompt injection pada level aplikasi.

## 12. Rencana Kegiatan

Berikut ini adalah tabel rangkaian rencana kegiatan kerja dalam penyusunan skripsi

**Tabel 2.** Rencana Kegiatan Kerja

| Rencana Kegiatan |                            |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
|------------------|----------------------------|----------|--|--|--|-------|--|--|--|-------|--|--|--|-----|--|--|--|------|--|
| No               | Kegiatan                   | 2026     |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
|                  |                            | Februari |  |  |  | Maret |  |  |  | April |  |  |  | Mei |  |  |  | Juni |  |
| 1                | Studi Literatur            |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
| 2                | Penulisan Proposal         |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
| 3                | Seminar Proposal           |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
| 4                | Perancangan Sistem         |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
| 5                | Implementasi dan Pengujian |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
| 6                | Penyusunan Skripsi         |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
| 7                | Seminar Hasil              |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |
| 8                | Sidang Meja Hijau          |          |  |  |  |       |  |  |  |       |  |  |  |     |  |  |  |      |  |

Disetujui oleh:

Pembimbing I



Handrizal, S.Si, M.Comp.Sc

NIP. 197706132017061001

Dibuat oleh:

Mahasiswa



Ronaldo D P Silitonga

NIM. 211401057

Pembimbing II



Hayaunnufus, S.Kom, M.Cs

NIP. 199207192024062001

### 13. Daftar Pustaka

1. Abdelnabi, S., Greshake, K., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). *Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection*. In *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (AISec '23)* (pp. 79–90). ACM. Akses dokumen: <https://doi.org/10.1145/3605764.3623985>
2. Hadiprakoso, R. B., Wilujengning, W., & Amiruddin, A. (2025). Adaptive multi-layer framework for detecting and mitigating prompt injection attacks in large language models. *Journal of Information Systems Engineering and Business Intelligence*, 11(3), 473–487. Akses dokumen: <https://e-journal.unair.ac.id/JISEBI/article/view/69403>
3. Jacob, D., Alzahrani, H., Hu, Z., Alomair, B., & Wagner, D. (2025). *PromptShield: Deployable Detection for Prompt Injection Attacks*. arXiv preprint. Akses dokumen: <https://arxiv.org/abs/2501.15145>
4. Lan, Q., Kaul, A., & Jones, S. (2025). Prompt Injection Detection in LLM Integrated Applications. *International Journal of Network Dynamics and Intelligence*, 4(2), 100013. Akses dokumen: <https://journal.hep.com.cn/ijndi/EN/10.53941/ijndi.2025.100013>
5. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. Akses dokumen: <https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>
6. Liu, Y., Deng, G., Li, Y., Wang, K., Wang, Z., Wang, X., Zhang, T., Liu, Y., Wang, H., Zheng, Y., Zhang, L. Y., & Liu, Y. (2023). *Prompt Injection Attack against LLM-Integrated Applications*. arXiv preprint arXiv:2306.05499. Akses dokumen: <https://arxiv.org/abs/2306.05499>
7. Shih, Y.-K., & Kang, Y.-K. (2025). *Design and Implementation of a Secure RAG-Enhanced AI Chatbot for Smart Tourism Customer Service: Defending Against*

- Prompt Injection Attacks – A Case Study of Hsinchu, Taiwan*. arXiv preprint. Akses dokumen: <https://arxiv.org/abs/2509.21367>
8. Su, H., Luo, W., Han, W., Liu, Y., Zhang, Y., Zhao, C., Zhang, J., & Mehdad, Y. (2025). LLM-friendly knowledge representation for customer support. In *Proceedings of the 31st International Conference on Computational Linguistics: Industry Track* (pp. 496–504). Association for Computational Linguistics. Akses dokumen: <https://aclanthology.org/2025.coling-industry.42/>
  9. Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing* (pp. 843–857). Association for Computational Linguistics. Akses dokumen: <https://aclanthology.org/2020.aacl-main.85/>
  10. Wu, S., Xiong, Y., Cui, Y., Wu, H., Chen, C., Yuan, Y., Huang, L., Liu, X., Kuo, T.-W., Guan, N., & Xue, C. J. (2024). *Retrieval-Augmented Generation for Natural Language Processing: A Survey*. arXiv preprint arXiv:2407.13193. Akses dokumen: <https://arxiv.org/abs/2407.13193>